

Especialização em Inteligência Artificial Generativa Aplicada

Engenharia de Contexto em RAG

Prof^a. Dra. Simone Dominico

Atividade – Engenharia de Contexto em RAG

Objetivo: analisar experimentalmente como diferentes decisões de engenharia de contexto afetam a qualidade, o custo e a confiabilidade de um pipeline RAG.

Utilizando o código completo trabalhado em aula, escolha uma **pergunta diferente das utilizadas nos exemplos** e que possa ser respondida a partir dos documentos indexados.

Alguns exemplos de perguntas possíveis são:

- Qual é a carga horária do estágio obrigatório?
- Quais são os requisitos para realização do estágio?
- Qual é a carga horária da disciplina de Banco de Dados?
- Quais conteúdos são previstos para a disciplina de Banco de Dados?

1. Definição da pergunta e do escopo

Apresente a pergunta escolhida e indique qual é o escopo esperado para a consulta:

curso, disciplina ou estagio.

Justifique brevemente a escolha do escopo.

2. Execução do pipeline baseline

Execute a pergunta utilizando o pipeline *baseline*, com busca por similaridade.

Registre:

- os três primeiros resultados recuperados;
- o escopo dos documentos recuperados;

- a quantidade aproximada de tokens;
- a latência da recuperação;
- se o primeiro resultado contém ou não evidência suficiente para responder à pergunta.

3. Execução do pipeline avançado

Execute a mesma pergunta utilizando o pipeline avançado de engenharia de contexto.

Observe e registre:

- as consultas geradas por *rewrite*, expansão, *step-back* e HyDE;
- a quantidade de candidatos recuperados;
- os resultados após filtros, deduplicação e *reranking*;
- a quantidade aproximada de tokens do contexto final;
- a decisão do pipeline: responder, esclarecer ou abster-se.

4. Comparação entre baseline e pipeline avançado

Compare as duas execuções considerando:

- relevância dos resultados;
- presença de ruído;
- redundância;
- adequação do escopo;
- quantidade de tokens;
- latência;
- suficiência do contexto.

Explique se o pipeline avançado produziu efetivamente um contexto melhor ou apenas tornou o processamento mais complexo.

5. Alteração experimental do pipeline

Escolha **uma decisão ou parâmetro do pipeline** e modifique seu comportamento.

Algumas possibilidades são:

- alterar o limiar de similaridade, por exemplo, de 0.20 para 0.40;
- alterar o orçamento de contexto, por exemplo, de 700 para 300 tokens;
- alterar o valor de λ do MMR;
- remover temporariamente o *reranking*;
- remover a deduplicação;
- comparar a recuperação com e sem filtro de escopo.

Execute novamente a consulta e descreva o que mudou.

Analise se a alteração produziu um contexto melhor ou apenas melhorou alguma métrica específica, como número de tokens, quantidade de candidatos ou latência.

6. Análise final

Responda às seguintes questões:

1. O pipeline avançado recuperou um contexto melhor que o baseline? Justifique.
2. Qual etapa do pipeline teve maior influência sobre o resultado?
3. Alguma técnica eliminou uma evidência útil ou introduziu ruído?
4. Qual configuração você utilizaria se esse pipeline fosse utilizado em uma aplicação real?
5. **Qual contexto você enviaria ao LLM e por que considera esse contexto suficiente para responder à pergunta?**

Resultados

Apresente os principais resultados em uma tabela comparativa semelhante à Tabela 1.

Conclusão

Apresente uma conclusão breve destacando:

- qual configuração produziu o melhor contexto;
- quais foram os principais *trade-offs* observados;
- por que o contexto escolhido é suficiente para responder à pergunta.

Tabela 1: Comparação entre as configurações avaliadas.

Critério	Baseline	Avançado	Alterado
Top-1 correto?			
Escopo correto?			
Quantidade de candidatos			
Tokens aproximados			
Latência			
Há ruído?			
Contexto suficiente?			