

RAG híbrido

Roteamento, dados estruturados e evidência

Prof^a. Dra. Simone Dominico

Especialização em IA Generativa


Objetivo da aula

Ao final, devemos conseguir:

- ▶ identificar o tipo de operação exigida pela pergunta;
- ▶ escolher entre vetor, SQL, grafo ou uma combinação;
- ▶ traduzir linguagem natural para estruturas executáveis;
- ▶ validar e executar consultas com controle;
- ▶ organizar evidências heterogêneas para o LLM;
- ▶ explicar de onde veio a resposta.

Foco

Controle da recuperação: escolher a rota e demonstrar qual evidência sustenta a resposta.



Corpus: o mesmo das aulas anteriores

PPC

Projeto Pedagógico do Curso

- ▶ carga horária;
- ▶ matriz curricular;
- ▶ estágio;
- ▶ TCC;
- ▶ estrutura do curso.

Estágio

Regulamento de Estágio

- ▶ modalidades;
- ▶ requisitos;
- ▶ documentação;
- ▶ validações;
- ▶ regras vigentes.

CI1218

Ficha 2 – Bancos de Dados

- ▶ pré-requisitos;
- ▶ carga horária;
- ▶ ementa;
- ▶ programa.

Onde paramos: pré e pós-processamento



Aula anterior

Melhoramos a pergunta antes da recuperação e melhoramos o contexto depois da recuperação.


Hoje

Antes de **executar a recuperação**, decidimos: qual mecanismo deve buscar a evidência?

A pergunta nova: qual rota deve recuperar a evidência?

A pergunta pode exigir operações diferentes:

- ▶ busca semântica: tema, significado, conteúdo;
- ▶ filtros: curso, documento, versão, tipo;
- ▶ agregações: contagem, soma, média, ranking;
- ▶ relações: pré-requisito, depende de, referencia;
- ▶ temporalidade: regra vigente, versão atual;
- ▶ permissão: o que pode ser consultado.




Pergunta → operação → mecanismo → evidência

Pergunta	Operação	Mecanismo	Evidência
Qual é a CH de CI1218?	busca factual	SQL/metadado	valor + origem
Quantas disciplinas obrigatórias têm 60h?	agregação	SQL	consulta + resultado
Quais regras vigentes falam de PET?	semântica + vigência	vetor + filtros	trecho vigente
Quais disciplinas antecedem CI1218?	relação	grafo	arestas/caminho
PPC e Regulamento são consistentes sobre estágio?	comparação	híbrido	trechos das fontes

Regra

A escolha deve seguir a estrutura da pergunta, não a tecnologia que temos disponível.

Do pipeline vetorial ao pipeline híbrido



O que muda?

Pré e pós-processamento continuam. A novidade é o **roteamento**: decidir se a evidência vem de vetor, SQL, grafo ou combinação.

Rotas implementadas

Rota	Quando usar	Exemplo
vetor	conteúdo, significado ou explicação	O que CI1218 aborda sobre transações?
sql	valor exato, soma, contagem, média	Qual é a CH total dos TCCs?
grafo	pré-requisito, dependência, caminho	Quais disciplinas antecedem CI1218?
vetor_sql	descobrir entidade e depois consultar valor	Qual é a CH da disciplina que trata de processamento de consultas?
vetor_grafo	descobrir conteúdo e depois seguir relação	Qual entidade relacionada ao tema depende de X?

Nem toda pergunta precisa do LLM em todas as etapas.

Roteamento: LLM com guardrails

O LLM ajuda a interpretar

- ▶ identifica intenção;
- ▶ classifica perguntas menos óbvias;
- ▶ lida com variação linguística.

O software restringe

- ▶ aceita apenas rotas conhecidas;
- ▶ resolve casos óbvios por regra;
- ▶ valida permissões;
- ▶ registra a decisão.

Exemplo

“Qual é a carga horária total do TCC1 e do TCC2?”

A operação já é clara: SUM. A rota esperada é sql.

Atividade inicial: classifique

Pergunta	Rota esperada
O curso possui estágio obrigatório?	
Qual é a carga horária total do curso?	
Quantas disciplinas obrigatórias têm 60h?	
Quais disciplinas antecedem CI1218?	
Quais regras vigentes falam sobre validação de PET?	
PPC e Regulamento são consistentes sobre estágio?	

Pergunta

Qual operação a pergunta exige antes de pensar na tecnologia?

Mapa de decisão: vetor, SQL, grafo ou híbrido?

A pergunta pede...	Use principalmente...
tema, significado, trechos parecidos	vetor
quantidade, soma, média, ranking	SQL
igualdade, datas, status, versão	SQL / metadados
pré-requisito, dependência, caminho	grafo
tema + valor exato	vetor + SQL
tema + relação explícita	vetor + grafo
mais de um desses aspectos	híbrido

Pergunta

“Qual é a carga horária da disciplina que trata de processamento de consultas e otimização?”

Parte semântica

“disciplina que trata de processamento de consultas”

VETOR

Parte exata

“qual é a carga horária”

SQL

Vetor encontra a entidade; SQL recupera o valor com precisão.


Pré-processamento na rota vetorial

Técnica	Função
Rewrite	tornar a consulta mais clara sem mudar a intenção
Multi-query	criar formulações alternativas da mesma necessidade
Step-back	formular uma pergunta um pouco mais geral
HyDE	gerar um texto hipotético usado somente para recuperação

Cuidado

HyDE ajuda a buscar; **não é evidência**. E reescritas podem causar *query drift* se acrescentarem temas que não estavam na pergunta.


Múltiplas buscas e RRF



Ideia

RRF combina rankings diferentes e favorece candidatos que aparecem bem posicionados em múltiplas buscas.

Pós-processamento vetorial



Recuperar candidatos não é o mesmo que selecionar o contexto que realmente deve chegar ao LLM.

SQL como recuperação: quando cálculo importa

Exemplos

- ▶ Quantas disciplinas obrigatórias possuem 60h?
- ▶ Qual é a carga horária total do curso?
- ▶ Qual é a carga horária total de TCC1 e TCC2?
- ▶ Quantos registros atendem a um filtro de versão?

```
SELECT SUM(carga_horaria)
FROM componentes
WHERE id IN (?, ?);
```

Regra

COUNT, SUM, AVG e filtros exatos não são operações de embedding.

Base estruturada mínima: SQLite derivado dos documentos

```
componentes(  
  id, nome, tipo,  
  carga_horaria,  
  obrigatorio,  
  fonte, versao  
)  
  
documentos(  
  id, titulo, escopo,  
  ano, versao  
)  
  
regras_estagio(  
  id, regra, valor,  
  unidade, fonte, versao  
)
```

PDFs

fonte textual

SQLite

controle, filtros e cálculo


RAG

combina evidências

Importante

A base estruturada não substitui os PDFs; ela organiza campos que exigem cálculo, filtro ou controle.

NL2SQL: linguagem natural para consulta



O modelo propõe; o sistema decide se pode executar.

Por que recuperar metadados antes do NL2SQL?

Problema observado

O modelo recebeu “TCC1” e tentou gerar:

```
WHERE nome LIKE '%TCC%'
```

Mas os dados reais eram:

- ▶ `id='TCC1', nome='Trabalho de Conclusao de Curso 1', tipo='tcc';`
- ▶ `id='TCC2', nome='Trabalho de Conclusao de Curso 2', tipo='tcc'.`

Solução

Antes do NL2SQL, recuperar dinamicamente schema, valores categóricos e entidades candidatas do próprio banco.

NL2SQL ou template determinístico?

	NL2SQL com LLM	Template determinístico
Quando	linguagem mais aberta	entidade e operação já resolvidas
Vantagem	flexibilidade	previsibilidade e menor custo
Risco	SQL plausível, mas errado	menos flexível
Proveniência	origem=llm	origem=template_deterministico

Transparência

Se o SQL foi montado por template, não devemos apresentar isso como um acerto do NL2SQL.

SQL parametrizado: por que aparece “?”?

Consulta executada

```
SELECT id, nome, carga_horaria  
FROM componentes  
WHERE id IN (?, ?);
```

```
params = ("TCC1", "TCC2")
```


Equivalência conceitual

```
SELECT id, nome, carga_horaria  
FROM componentes  
WHERE id IN ('TCC1', 'TCC2');
```

Por quê?

Parâmetros reduzem risco de SQL injection e evitam concatenação insegura de valores.

Validação SQL: AST + defesa em profundidade



Produção

Parser/AST, permissões reais, limites de custo, isolamento e observabilidade continuam necessários.

Custo de execução: EXPLAIN e limites

```
plano = conn.execute(  
    "EXPLAIN QUERY PLAN " + sql,  
    params  
)  
.fetchall()  
  
resultado = conn.execute(  
    sql, params  
)  
.fetchmany(MAX_ROWS)
```

- ▶ EXPLAIN ajuda a discutir custo;
- ▶ fetchmany limita respostas enormes;
- ▶ logs permitem auditoria;
- ▶ consultas amplas podem exigir recusa.


Ponto

Mesmo um SELECT pode ser caro, lento ou amplo demais.

Ambiguidade: quando perguntar antes de consultar

Ambiguidade mal resolvida produz SQL plausível, mas possivelmente errado.

- ▶ “Qual é a carga horária?” – de quê?
- ▶ “recentes” – últimos 30 dias ou última versão?
- ▶ “relacionadas a Banco de Dados” – nome, ementa ou área?
- ▶ “documentos vigentes” – por data ou status?



Evidência estruturada: a resposta deve carregar sua prova

Pergunta

Qual é a carga horária de CI1218?

```
SELECT id, nome, carga_horaria  
FROM componentes  
WHERE id = ?;
```

params = ('CI1218',)

Resultado


CI1218 – Bancos de Dados – 60h

Evidência

SQL executado + parâmetros + resultado + origem documental.

Relações explícitas: quando similaridade não basta


- ▶ pré-requisito;
- ▶ depende de;
- ▶ referencia;
- ▶ regulamenta;
- ▶ pode validar como.



Ideia

Uma relação pode ser recuperada por uma aresta em vez de inferida pela similaridade entre chunks.

Grafo mínimo para recuperação por relações



Escopo da aula

Estamos demonstrando recuperação por relações. Não é um framework GraphRAG completo.

NL2Graph: linguagem natural para consulta de grafo

Pergunta: Quais são os pré-requisitos da CI1218?

```
{  
  "entidade": "CI1218",  
  "relacoes": ["pre_requisito_de"],  
  "direcao": "entrada"  
}
```

Execução

O LLM traduz a pergunta para uma estrutura; o software valida e percorre o grafo.

Código do grafo: percorrer relações

```
import networkx as nx
G = nx.DiGraph()

G.add_edge(
    "CI1057", "CI1218",
    relacao="pre_requisito_de"
)


antecedentes = nx.ancestors(
    G, "CI1218"
)
```

- ▶ arestas têm significado explícito;
- ▶ resposta pode incluir o caminho;
- ▶ relações precisam ser modeladas ou extraídas;
- ▶ manutenção do grafo tem custo.

Caso principal: vetor + SQL

Pergunta

Qual é a carga horária da disciplina que trata de processamento de consultas e otimização?



Entity resolution

A busca gera candidatos; o sistema resolve qual entidade estruturada corresponde à descrição da pergunta.

Quando o SQL vem de template

Depois de resolver:

entidade = CI1218 operação = carga horária


Não há mais incerteza suficiente para justificar outra geração pelo LLM.

```
SELECT id, nome, carga_horaria, fonte, versao  
FROM componentes  
WHERE id IN (?);
```

Híbrido: vetor + grafo + SQL

Pergunta


Qual a carga horária das disciplinas relacionadas a Banco de Dados que antecedem CI1218?



Ideia

Cada mecanismo executa a parte da pergunta para a qual é mais apropriado.

Permissões: controle não pode depender do LLM



- ▶ a busca vetorial aplica filtros de permissão;
- ▶ SQL verifica escopo na camada de execução;
- ▶ grafo verifica entidades autorizadas;
- ▶ o roteador não é a única barreira.

Regra

Segurança não deve depender de o LLM classificar corretamente a pergunta.

Versionamento: embeddings também ficam desatualizados

Documento	Versão texto	Versão em- bedding	Estado
Regulamento de Estágio	2024	2023	inválido
PPC	2018	2018	válido
Ficha CI1218	atual	atual	válido

Caso concreto

Se uma regra foi incluída em 2024, um índice construído sobre uma versão anterior não contém essa evidência.

Pós-processamento agora organiza evidências heterogêneas

Antes

- ▶ chunks;
- ▶ reranking;
- ▶ compressão;
- ▶ deduplicação.

Agora

- ▶ trecho de PDF;
- ▶ resultado SQL;
- ▶ relação/caminho no grafo;
- ▶ versão;
- ▶ escopo/permissão;
- ▶ proveniência do SQL.

Nova função

Transformar evidências diferentes em um contexto estruturado e explicável para o LLM final.

Contexto suficiente depende da rota

Rota	Quando consideramos suficiente?
Vetor	boa cobertura semântica e evidência relevante
SQL	consulta validada + resultado estruturado
Grafo	consulta válida + relações encontradas
Vetor + SQL	entidade resolvida + resultado SQL
Vetor + grafo	evidência semântica + relação explícita

Logs: rastreabilidade significa reconstruir a resposta

```
{  
  "pergunta": ...,  
  "rota": ...,  
  "ids_refinados": ...,  
  "sql": ...,  
  "sql_params": ...,  
  "estrategia_sql": ...,  
  "consulta_grafo": ...,  
  "fontes": ...,  
  "latencia": ...  
}
```

- ▶ rota escolhida;
- ▶ entidades resolvidas;
- ▶ SQL e parâmetros;
- ▶ estratégia: LLM ou template;
- ▶ documentos/chunks;
- ▶ versão;
- ▶ tempo de execução.

Pergunta

Se alguém contestar a resposta amanhã, conseguimos reconstruir o caminho?

Demonstração 1: pergunta vetorial

Pergunta

O que a disciplina de Bancos de Dados aborda sobre processamento de consultas?

Observe no notebook:

1. pré-processamento da consulta;
2. múltiplas buscas;
3. RRF;
4. deduplicação, reranking e compressão;
5. evidências finais.

Demonstração 2: pergunta SQL

Pergunta

Qual é a carga horária total do TCC1 e do TCC2?

Observe no notebook:

1. teste direto do SQLite;
2. descoberta dinâmica de schema/metadados;
3. estratégia usada para gerar a consulta;
4. AST + execução read-only;
5. resultado estruturado.

Pergunta

Precisávamos de embeddings para somar dois valores já estruturados?

Demonstração 3: pergunta de grafo

Pergunta

Quais são os pré-requisitos da CI1218?

Observe no notebook:

1. NL2Graph / regra controlada;
2. entidade, relação e direção;
3. validação;
4. travessia no NetworkX;
5. relações retornadas como evidência.

Demonstração 4: caso híbrido principal

Pergunta

Qual é a carga horária da disciplina que trata de processamento de consultas e otimização?

Observe no notebook:

1. busca vetorial encontra candidatos;
2. resolução/refinamento da entidade;
3. CURSO, CI1218 $\rightarrow$ CI1218;
4. SQL usa a entidade resolvida;
5. saída registra se foi LLM ou template.


Atividade final: escolha rota e evidência

Pergunta	Rota	Evidência esperada
O que CI1218 aborda sobre transações?		
Qual é a carga horária total do TCC1 e do TCC2?		
Quais são os pré-requisitos da CI1218?		
Qual é a CH da disciplina que trata de processamento de consultas?		
Quando o aluno pode realizar estágio obrigatório?		

Pergunta-guia

Qual evidência sustentaria uma resposta confiável?

Pipeline final: arquitetura de recuperação híbrida



O papel do LLM e do software tradicional

LLM é útil para

- ▶ interpretar linguagem natural;
- ▶ reformular consultas;
- ▶ traduzir NL para SQL/grafos;
- ▶ sintetizar respostas.

Software deve controlar

- ▶ cálculo exato;
- ▶ permissões;
- ▶ validação;
- ▶ execução;
- ▶ versionamento e logs.

IA generativa não significa colocar LLM em tudo.

Fechamento: regra final de decisão

Quando a pergunta exige...	Decisão prática
recall semântico	vetor
precisão, cálculo ou agregação	SQL
relações explícitas ou caminhos	grafo
escopo, vigência ou permissão	filtros antes da recuperação
resposta auditável	registrar rota, consulta, fonte e versão
mais de um desses aspectos	abordagem híbrida

Pergunta final

Qual evidência sustenta a sua resposta?