

Especialização em Inteligência Artificial Generativa Aplicada



Prof. Dr. Anderson Ara

DSLLMS

Fundamentos de Inferência Estatística


O que veremos hoje?

A **inferência estatística** é o conjunto de métodos usados para aprender sobre fenômenos desconhecidos a partir de dados observados.


Nos LLMs, praticamente tudo depende de inferência:

- estimar probabilidades;
- ajustar parâmetros;
- generalizar para novos textos;
- medir incerteza.


Considere o gráfico de dispersão entre **renda** versus **anos de experiência** para 30 indivíduos.




Considere agora este gráfico de dispersão:




Considere agora este gráfico de dispersão:



Considere agora:



Considere agora:



Regressão Linear Simples

Suponha que desejamos observar uma resposta quantitativa Y e X como sua possível preditora. Assumimos que há alguma relação entre Y e X que pode ser escrita na forma

$$Y = f(X) + \varepsilon$$

sendo que $f(X)$ é alguma função fixa e desconhecida de X , ε é um termo de erro aleatório, independente e com média zero. Nesta formulação, f representa a informação sistemática que X fornece sobre Y .

Regressão Linear Simples

Suponha $f(X) = \beta_0 + \beta_1 X$, então:

$$Y = \beta_0 + \beta_1 X + \varepsilon$$

β_0 e β_1 são duas constantes desconhecidas e representam os termos de intercepto e o coeficiente angular no modelo de regressão linear simples. Juntos, β_0 e β_1 são conhecidos como coeficientes ou **parâmetros** do modelo.

Utilizamos os dados de treinamento para produzir estimativas $\hat{\beta}_0$ e $\hat{\beta}_1$ para os parâmetros dos modelos.

Regressão Linear Simples

Para uma amostra aleatória de (X_i, Y_i) , com $i = 1, \dots, n$, temos que

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i$$

Suponha que, para a i -ésima observação, y_i represente a variável de resposta e x_i a variável preditora. Então, nossos dados de treinamento consistem em $\{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$. E, para quaisquer valores candidatos para estimar β_0 e β_1 , temos que:

$$e_i = y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i)$$

sendo e_i o erro aleatório observado para a i -ésima observação, $\hat{\beta}_0$ e $\hat{\beta}_1$ candidatos para estimar os parâmetros.

Regressão Linear Simples

Seja

$$Q(\beta_0, \beta_1) = e_1^2 + e_2^2 + \dots + e_n^2 = \sum_{i=1}^n e_i^2$$

Para o Método de Mínimos Quadrados (Ordinários) procuramos o

$$\begin{aligned} & \min_{\beta_0, \beta_1} Q(\beta_0, \beta_1) \\ &= \min_{\beta_0, \beta_1} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2 \end{aligned}$$

Regressão Linear Múltipla

A regressão linear simples é uma abordagem útil para prever uma resposta com base em uma única variável preditora. No entanto, na prática, muitas vezes temos mais de um preditora

Para uma amostra aleatória de $(\mathbf{X}_i, Y_i)$, com $\mathbf{X}_i = (X_{1_i}, \dots, X_{p_i})$ e $i = 1, \dots, n$, temos que


$$Y_i = \beta_0 + \beta_1 X_{1_i} + \beta_2 X_{2_i} + \dots + \beta_p X_{p_i} + \varepsilon_i$$

com $\varepsilon_i \sim N(0, \sigma^2)$.

Note que $E(Y_i) = \mu_i = \beta_0 + \beta_1 X_{1_i} + \beta_2 X_{2_i} + \dots + \beta_p X_{p_i}$.

E, de forma equivalente, $Y_i \sim N(\mu_i, \sigma^2)$.

Regressão Linear Múltipla



Adaptado de: JAMES, Gareth et al. An introduction to statistical learning. New York: springer, 2013.

Regressão linear múltipla e inferência estatística

A regressão linear múltipla busca modelar a relação entre uma variável resposta e várias variáveis explicativas.

Exemplo:

prever preço de uma casa usando:

- metragem;
- número de quartos;
- localização.

O modelo é ajustado utilizando uma **amostra** retirada de uma população.

Regressão linear múltipla e inferência estatística

A partir dessa amostra, estimamos parâmetros desconhecidos da população.

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \cdots + \beta_p X_{ip} + \varepsilon_i$$

sendo:

- os β_j representam parâmetros populacionais desconhecidos;
- os dados observados fornecem estimativas desses parâmetros.

Estimação pontual e intervalar

Ao ajustar o modelo, obtemos:

- estimativas pontuais dos coeficientes;
- medidas de incerteza dessas estimativas.

Exemplo: $\hat{\beta}_1 = 2.4$

Interpretação:

mantendo as demais variáveis fixas, um aumento unitário em X_1 aumenta em média 2.4 unidades em Y .

Mas essa estimativa depende da amostra observada.

Por isso também construímos intervalos de confiança: $IC(95\%) = [1.8, 3.0]$

A inferência estatística permite avaliar:

Regressão, modelos estatísticos e algoritmos em LLMs

Grande parte da Inteligência Artificial moderna pode ser vista como uma extensão dos modelos estatísticos clássicos.

Na regressão linear, por exemplo, ajustamos parâmetros usando uma amostra:

$$Y = X\beta + \varepsilon$$

O objetivo é encontrar coeficientes que expliquem os dados observados.

Nos LLMs ocorre uma ideia semelhante:

- existe uma enorme quantidade de parâmetros;
- os parâmetros são ajustados usando dados;
- buscamos minimizar uma função de erro (função de perda).

A principal diferença é a escala e a complexidade do modelo.

Regressão, modelos estatísticos e algoritmos em LLMs

Enquanto uma regressão linear pode possuir poucos parâmetros, LLMs possuem:

- milhões;
- bilhões;
- ou até trilhões de parâmetros.

Mesmo assim, ambos dependem de:

- inferência estatística;
- estimação;
- otimização;
- generalização.

Modelos estatísticos vs algoritmos

É importante diferenciar:

Modelo estatístico

Representa a estrutura matemática do problema.

Exemplos:

- regressão linear;
- regressão logística;
- redes neurais;
- transformers.

Algoritmo

É o procedimento computacional usado para ajustar o modelo.

Exemplos:

- mínimos quadrados;
- gradient descent;
- stochastic gradient descent (SGD);
- Adam optimizer.

Nos LLMs:

- o transformer é o modelo;
- Adam e backpropagation são algoritmos de treinamento.

A ideia central dos LLMs

Um LLM tenta prever o próximo token mais provável dado um contexto.

Exemplo:

█ “A capital do Paraná é __”

Probabilidades possíveis:

- Curitiba $\rightarrow 0.92$
- Londrina $\rightarrow 0.04$
- Maringá $\rightarrow 0.02$

LLMs trabalham com distribuições probabilísticas.

Um transformer pode ser visto como uma regressão extremamente complexa?

A regressão linear transforma entradas em uma previsão baseada em:

$$Y = X\beta + \varepsilon$$

De forma análoga, um LLM recebe uma entrada textual e produz uma previsão probabilística para o próximo token.

entrada → embeddings → parâmetros → função de perda → otimização → predição

Um transformer pode ser visto como uma regressão extremamente complexa?

A diferença principal está na escala:

- na regressão, temos poucos parâmetros interpretáveis;
- em um transformer, temos milhões ou bilhões de parâmetros;
- em ambos, os parâmetros são estimados a partir de uma amostra;
- em ambos, queremos boa generalização para dados novos.

A ideia estatística permanece a mesma:

ajustar uma função aos dados para prever melhor observações ainda não vistas.


População e amostra

Parâmetros são quantidades desconhecidas que descrevem características de uma população, como médias, proporções ou taxas de falha.

Como geralmente é inviável observar toda a população, utilizamos uma amostra para estimar esses parâmetros e obter informações sobre o comportamento populacional.

A Figura exhibe a ideia da amostragem, sendo o parâmetro denotado pela letra grega θ e a estimativa do parâmetro denotada por $\hat{\theta}$.

População e amostra



População e amostra

Na estatística clássica:

- população → conjunto completo;
- amostra → subconjunto observado.

Nos LLMs:

- população → todos os textos possíveis;
- amostra → corpus de treinamento.

A qualidade da inferência depende fortemente da qualidade da amostra.

Variáveis aleatórias


Uma variável aleatória representa resultados possíveis associados a probabilidades.

- **Variável aleatória:** Descrição numérica do resultado de um experimento aleatório.
- **Notação:** Y denota a variável aleatória, enquanto y denota os valores realizados de uma variável aleatória.



Exemplo: Lançamento de uma moeda

Lançamento de duas moedas honestas e defina Y = número de resultados cara (C).



Variável aleatória definida sobre pontos do espaço amostral.

Outros exemplos

- Em um sistema de moderação automática baseado em LLM, uma resposta gerada pode ser classificada quanto à presença de conteúdo inadequado. Defina a v.a.

$$Y = \begin{cases} 1, & \text{se a resposta contém conteúdo inadequado} \\ 0, & \text{se a resposta é considerada segura.} \end{cases}$$

- Número de tokens gerados por um LLM em uma resposta.
- Tempo (em segundos) necessário para um modelo gerar uma resposta.
- Número de erros factuais (“hallucinations”) encontrados em uma resposta gerada.



Tipos de variáveis aleatórias

Espaço amostral

- Reta real, $\Omega = \mathbb{R}$.
- Estritamente positivos, $\Omega = \mathbb{R}_+$.
- Positivos com zero, $\Omega = \mathbb{R}_0^+ = [0, \infty)$.
- Proporções ou índices limitados, $\Omega = (0, 1)$.
- Direções, $\Omega = [0, 2\pi)$.
- Contagem, $\Omega = \mathbb{N}_0 = \{0, 1, 2, \dots\}$.
- Contagem limitada, $\Omega = \{0, 1, 2, \dots, m\}$.

Tipos de variáveis aleatórias

Classificação

- Tipos de espaço amostral
 - Discreto: contém número finito ou contável de elementos.
 - Contínuo: contém número infinito e não contável de elementos.
- Tipos de variáveis aleatórias
 - A variável aleatória é **discreta** se seu espaço amostral é discreto.
 - A variável aleatória é **contínua** se seu espaço amostral é contínuo.

Exemplo direto

| X = próximo token após “bom dia”

Possíveis valores:

- “!”
- “professor”
- “senhor”

Cada token possui uma probabilidade associada.

Probabilidade condicional

Grande parte dos LLMs pode ser resumida por:

- ▮ prever um token condicionado ao contexto anterior.

Exemplo:

A probabilidade da palavra “chuva” muda dependendo da frase anterior.

O contexto altera as probabilidades.

Probabilidade condicional

Teorema de Bayes

"An Essay Towards Solving a Problem in Doctrine of Chance". Philosophical Transactions of the Royal Society of London, 1763"

Trabalho submetido por Richard Price e que não apresenta a definição do clássico Teorema de Bayes:

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

Probabilidade condicional

Teorema de Bayes

- Definição foi dada por Laplace (1774)

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

- O trabalho original de Bayes é mais voltado para definições conceituais.
- Foi Laplace que formulou o teorema, tanto em sua forma discreta quanto em sua forma contínua.

Probabilidade condicional

Teorema de Bayes

- (1) A probabilidade conjunta entre um evento A e um evento B é dada por:

$$P(A \cap B) = P(A|B) P(B);$$

- (2) Essa probabilidade conjunta também pode ser representada por:

$$P(B \cap A) = P(A \cap B) = P(B|A)P(A);$$

- (3) Combinando (1) e (2), tem-se:

$$P(A|B)P(B) = P(B|A)P(A);$$

Probabilidade condicional

Teorema de Bayes

- (4) Reorganizando (3), tem-se:

$$P(A|B) = \frac{P(A \cap B)}{P(B)} = \frac{P(B|A)P(A)}{P(B)};$$

- (5) Geralmente $P(B)$ não é conhecido, então deve-se utilizar uma formulação alternativa, que é dada por:

$$P(B) = P(A \cap B) + P(A^c \cap B),$$

em que $P(A^c)$ é a probabilidade complementar de A , isto é, probabilidade de A não ocorrer;

Probabilidade condicional

Teorema de Bayes

- (6) Combinando (2) e (5), tem-se:

$$P(B) = P(B|A)P(A) + P(B|A^c)P(A^c).$$

Logo, o Teorema de Bayes é descrito por:

$$\begin{aligned} P(A|B) &= \frac{P(B|A)P(A)}{P(B|A)P(A) + P(B|A^c)P(A^c)} \\ &= \frac{P(B|A)}{P(B|A)P(A) + P(B|A^c)P(A^c)} P(A). \end{aligned}$$

Probabilidade condicional

Teorema de Bayes

Supondo o espaço dos eventos é dado em termos de A_j eventos exclusivos e exaustivos, com $j = 1, \dots, k$, ou seja, que não possuem intersecção entre si e que a união deles retorna o espaço amostral. Logo, pela lei da probabilidade total, o cálculo da $P(B)$ é dado por

$$P(B) = \sum_{j=1}^k P(B \cap A_j) = \sum_{j=1}^k P(B|A_j)P(A_j).$$

Probabilidade condicional

Teorema de Bayes

Por fim, o Teorema de Bayes pode ser descrito como

$$P(A_j|B) = \frac{P(B|A_j)}{\sum_{i=1}^k P(B|A_i)P(A_i)}P(A_j) \propto P(B|A_j)P(A_j),$$

sendo $P(A_j)$ probabilidade *a priori* do evento A_j , $P(A_j|B)$ probabilidade *a posteriori* do evento A_j , $P(B|A_i)$ e $\sum_{i=1}^k P(B|A_i)P(A_i)$ conhecidas como verossimilhança e constante normalizadora, respectivamente.

Probabilidade condicional

Teorema de Bayes :: Exemplo Detecção de Alucinação em LLMs

Suponha que, em um sistema baseado em LLM, aproximadamente 12% das respostas geradas contenham algum erro factual (*hallucination*).

Considere um detector automático de alucinações com sensibilidade (s) 91% e especificidade (e) 96%.

Qual a probabilidade de uma resposta conter alucinação dado que o detector classificou a resposta como segura?

Qual a $P(H = 1 | A = -)$?

$$s = P(A = + | H = 1) = 0,91$$

$$e = P(A = - | H = 0) = 0,96$$

Probabilidade condicional

Teorema de Bayes :: Exemplo Detecção de Alucinação em LLMs

$$\begin{aligned} P(H = 1|A = -) &= \frac{P(H = 1 \cap A = -)}{P(A = -)} \\ &= \frac{P(A = -|H = 1)P(H = 1)}{P(A = -)} \end{aligned}$$

$$\begin{aligned} P(A = -) &= P(\{H = 1 \cap A = -\} \cup \{H = 0 \cap A = -\}) \\ &= P(A = -|H = 1)P(H = 1) + P(A = -|H = 0)P(H = 0) \end{aligned}$$

Probabilidade condicional

Teorema de Bayes :: Exemplo Detecção de Alucinação em LLMs

$$P(H = 1) = 0,12 \text{ e } P(H = 0) = 0,88$$

$$P(A = -|H = 0) = e = 0,96$$

$$P(A = -|H = 1) = 1 - P(A = +|H = 1) = 1 - s = 1 - 0,91 = 0,09$$

$$\begin{aligned} P(H = 1|A = -) &= \frac{P(H = 1 \cap A = -)}{P(A = -)} \\ &= \frac{P(A = -|H = 1)P(H = 1)}{P(A = -|H = 1)P(H = 1) + P(A = -|H = 0)P(H = 0)} \\ &= \frac{0,09 \times 0,12}{0,09 \times 0,12 + 0,96 \times 0,88} = 0,01262626 \text{ ou } 1,26\% \end{aligned}$$

Probabilidade condicional

Teorema de Bayes :: Exemplo Detecção de Alucinação em LLMs

O teorema de Bayes é amplamente utilizado em IA generativa para atualizar probabilidades com base em evidências observadas.

- $P(H = 1) = 12\%$
- $P(H = 1|A = -) = 1,26\%$

Mesmo quando o detector afirma que a resposta é segura, ainda existe uma pequena probabilidade residual de alucinação.

Distribuições de probabilidade

Exemplo simples:

Token	Probabilidade
Curitiba	0.92
Londrina	0.04
Maringá	0.02

A soma das probabilidades deve ser igual a 1.

A camada softmax transforma scores internos em probabilidades.

Distribuições de probabilidade

Um LLM tenta modelar:

$$P(w_t \mid w_1, w_2, \dots, w_{t-1})$$

Ou seja:

▮ a probabilidade da próxima palavra dado todo o contexto anterior.

Essa é exatamente uma distribuição condicional de probabilidade.

Distribuições de probabilidade

Cadeia de Probabilidades

Uma frase inteira pode ser vista como:

$$P(w_1, w_2, \dots, w_n)$$

Usando a regra da cadeia:

$$P(w_1, \dots, w_n) = P(w_1)P(w_2|w_1)P(w_3|w_1, w_2) \dots P(w_n|w_1, \dots, w_{n-1})$$

Os LLMs aprendem justamente essas probabilidades condicionais.

Distribuições de probabilidade

Exemplo Intuitivo

Considere as frases:

- “O gato subiu no telhado”
- “O gato tomou café”

A primeira frase possui alta probabilidade porque aparece frequentemente em padrões linguísticos naturais.

A segunda possui menor probabilidade porque é semanticamente menos comum.

LLMs aprendem padrões estatísticos de coocorrência presentes em bilhões de textos.

Distribuições de probabilidade

Tokens e Distribuições

Os modelos não trabalham diretamente com palavras completas.

Eles utilizam **tokens**.

Exemplos:

Texto	Tokens possíveis
computador	comput + ador
running	run + ning
ChatGPT	Chat + GPT

Para cada passo, o modelo produz uma distribuição de probabilidade sobre milhares de tokens possíveis.

Distribuições de probabilidade

Saída Probabilística do Modelo

Ao final da rede neural, o modelo produz números chamados de *logits*:

Token	Logit
azul	8.2
verde	5.1
carro	1.0

Esses valores ainda não são probabilidades.

Precisamos transformá-los.

Distribuições de probabilidade

Função Softmax

A transformação é feita pela função Softmax:

`:contentReference[oaicite:0]{index=0}`

Ela converte logits em probabilidades válidas:

- valores entre 0 e 1;
- soma total igual a 1.

Distribuições de probabilidade

Exemplo de Softmax

Após aplicar Softmax:

Token	Probabilidade
azul	0.91
verde	0.07
carro	0.02

Agora temos uma distribuição de probabilidade discreta. O modelo pode:

- escolher o maior valor (*greedy*);
- amostrar aleatoriamente;
- aplicar temperatura.

Distribuições de probabilidade

Modelo de linguagem bigrama

Um dos modelos probabilísticos clássicos em Processamento de Linguagem Natural (NLP) consiste em prever a próxima palavra considerando apenas a palavra anterior.

Nesse contexto, calculamos:

$$P(w_t \mid w_{t-1}) = \frac{\text{count}(w_{t-1}, w_t)}{\text{count}(w_{t-1})}$$

sendo:

- w_t = palavra atual;
- w_{t-1} = palavra anterior;
- $\text{count}(w_{t-1}, w_t)$ = número de vezes que o par aparece no corpus;
- $\text{count}(w_{t-1})$ = frequência da palavra anterior.

Distribuições de probabilidade

Exemplo

Se no corpus observamos:

tempo perdido
tempo perdido
tempo acabou

Então:

$$P(\text{perdido} \mid \text{tempo}) = \frac{2}{3}$$

Distribuições de probabilidade

Modelos bigrama foram uma das bases históricas para:

- modelos de linguagem probabilísticos;
- redes neurais para NLP;
- embeddings;
- transformers;
- Large Language Models (LLMs).

A principal diferença é que os LLMs modernos utilizam contextos muito maiores e representações vetoriais complexas para estimar probabilidades de próxima palavra/token.

Distribuições de probabilidade

A temperatura controla o quão “criativa” é a distribuição.

- Temperatura baixa:
 - distribuição concentrada;
 - respostas mais previsíveis.
- Temperatura alta:
 - distribuição mais espalhada;
 - respostas mais variadas.

Distribuições de probabilidade

Distribuição Normal Univariada

Uma variável aleatória contínua X segue distribuição normal com $x \in \mathbb{R}$ e parâmetros $\mu \in \mathbb{R}$ e $\sigma^2 > 0$, $X \sim N(\mu, \sigma^2)$.

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left\{-\frac{(x - \mu)^2}{2\sigma^2}\right\}$$

sendo os parâmetros μ e σ^2 , respectivamente, a esperança e a variância de X .

Distribuições de probabilidade

Distribuição Normal Multivariada


Um vetor aleatório contínuo $\mathbf{X} = (X_1, \dots, X_p)$ segue distribuição normal multivariada com parâmetros $\boldsymbol{\mu} \in \mathbb{R}^p$ e $\boldsymbol{\Sigma}$, $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$.

$$f(\mathbf{x}) = \frac{1}{(2\pi)^{\frac{p}{2}} |\boldsymbol{\Sigma}|^{\frac{1}{2}}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})' \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right\}$$

sendo $\mathbf{X}$ o vetor de médias e $\boldsymbol{\Sigma}$ a matriz de variância e covariância.

$\mathbf{X}$ tem distribuição normal multivariada se qualquer combinação linear de seus componentes $\sum_{j=1}^p a_j X_j$ tem uma distribuição normal.

Distribuições de probabilidade



Distribuições de probabilidade

Existem várias distribuições de probabilidade para representar diferentes tipos de variáveis.

Variáveis **contínuas** podem ser modeladas, por exemplo, por distribuições como: *Normal*, *Exponencial*, *Gama*, *Beta*, etc.

Já variáveis **discretas** podem ser modeladas por distribuições como: *Bernoulli*, *Binomial*, *Poisson*, *Multinomial*, etc.

Em **LLMs**, o foco principal está em distribuições de probabilidade para variáveis **discretas**, pois o modelo precisa escolher o próximo **token** dentro de um vocabulário finito.

A saída de um LLM pode ser vista como uma distribuição de probabilidade sobre tokens:

$$P(\text{próximo token} \mid \text{texto anterior})$$

Embora existam muitas distribuições contínuas e discretas, os LLMs trabalham principalmente com distribuições discretas sobre palavras, subpalavras ou tokens.

Teorema Central do Limite

Em LLMs, muitas métricas são calculadas como **médias sobre várias unidades**: tokens, respostas, prompts, documentos ou usuários.

Por exemplo, podemos avaliar um modelo pela média da perda em uma amostra de prompts:

$$\bar{L} = \frac{1}{n} \sum_{i=1}^n L_i$$

em que L_i representa a perda, erro ou pontuação associada ao i -ésimo prompt.

Teorema Central do Limite


Pelo Teorema Central do Limite, quando n é suficientemente grande, a distribuição de $\bar{L}$ tende a se aproximar de uma distribuição normal:

$$\bar{L} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

com μ e σ^2 a média e variância de L_i . Isso permite construir **intervalos de confiança** e comparar modelos com base em amostras, mesmo quando a distribuição original dos erros não é normal.

No contexto de LLMs, o TCL ajuda a transformar avaliações amostrais em inferência estatística sobre o desempenho médio do modelo.

Teorema Central do Limite Distribuição Binomial



Distribuições de probabilidade

LLMs utilizam diversos conceitos estatísticos:

- distribuições de probabilidade;
- inferência;
- máxima verossimilhança;
- entropia;
- estimação paramétrica;
- otimização.

De certa forma:

■ um LLM é um enorme modelo probabilístico para linguagem natural.

Estimação estatística

Inferência estatística frequentemente significa:

- estimar parâmetros desconhecidos usando dados.

Nos LLMs, os parâmetros são os pesos da rede neural.

Treinar o modelo significa encontrar bons valores para esses parâmetros.

Exemplo intuitivo de estimação

Corpus pequeno:

“IA é interessante”

“IA é poderosa”

“IA é moderna”

A palavra “é” aparece após “IA” em todos os casos.

Então:

$$P(\text{“é”} | \text{“IA”}) \approx 1$$

Estimação estatística

Um LLM aprende a partir de muitos exemplos de texto.

Cada observação (exemplo) contribui com uma pequena informação sobre os parâmetros do modelo.

- Ex: Teorema Central do Limite

Estimação estatística

No treinamento de LLMs, a ideia aparece quando estimamos quantidades como:

perda média, gradientes médios, probabilidades médias de tokens e incerteza das estimativas.

Assim, o TCL ajuda a justificar por que podemos usar amostras de textos para inferir padrões gerais da linguagem.

Em outras palavras: o modelo não observa toda a linguagem possível, mas usa grandes amostras para estimar regularidades estatísticas.

Generalização

Objetivo principal:

- | funcionar bem em dados nunca vistos.

Exemplo:

Treinar em notícias e artigos científicos e depois responder:

- | “Explique computação quântica para uma criança.”

O modelo precisa combinar padrões aprendidos anteriormente.

Viés e variância

Modelos simples:

- alto viés;
- pouca flexibilidade.

Modelos excessivamente complexos:

- alta variância;
- risco de memorizar dados.

Esse equilíbrio aparece em praticamente toda IA moderna.

Overfitting

Overfitting ocorre quando o modelo aprende excessivamente os dados de treino.

Exemplo:


Um chatbot treinado apenas com textos jurídicos pode responder:


■ “Boa tarde”

com:

■ “Nos termos do artigo 5º...”

O modelo perdeu capacidade de generalização.





Máxima verossimilhança

Ideia central:

- | escolher parâmetros que tornem os dados observados os mais prováveis possíveis.

Treinar um LLM é essencialmente maximizar verossimilhança.

Cross-entropy

Queremos reduzir o erro entre:

- distribuição real;
- distribuição prevista.

Exemplo:

Distribuição real:

- Curitiba $\rightarrow 1$

Distribuição prevista:

- Curitiba $\rightarrow 0.60$
- Londrina $\rightarrow 0.25$

A cross-entropy mede essa diferença.

Inferência Bayesiana

A inferência Bayesiana atualiza crenças conforme novos dados aparecem.

Ideia:

■ conhecimento anterior + dados observados.

Muito utilizada em:

- uncertainty estimation;
- modelos probabilísticos;
- sistemas inteligentes.

Temperatura em LLMs

A temperatura controla o grau de aleatoriedade na geração de texto.

O modelo produz probabilidades para os próximos tokens:

- "cachorro" → 0,45
- "gato" → 0,30
- "pássaro" → 0,10
- outros → 0,15

A temperatura modifica essa distribuição probabilística antes da amostragem.

- Temperaturas baixas tornam a distribuição mais concentrada.
- Temperaturas altas deixam a distribuição mais uniforme.

Quanto maior a temperatura:

- maior diversidade;
- maior criatividade;

Temperatura e distribuição probabilística

Ajustamos as probabilidades utilizando:

$$P_i^{(\text{temp})} = \frac{\exp(z_i/T)}{\sum_j \exp(z_j/T)}$$

em que z_i são os “scores brutos” para cada palavra/token produzidos pelo modelo e T representa a temperatura.

Se $T < 1$:

- tokens mais prováveis dominam;
- respostas ficam mais determinísticas.

Se $T > 1$:

- aumenta a chance de tokens menos prováveis;
- respostas ficam mais variadas.

Escolha prática da temperatura

Exemplo:

- $T = 0.2 \rightarrow$ resumo técnico e previsível.
- $T = 1.5 \rightarrow$ geração mais criativa e imprevisível.

A escolha da temperatura depende da tarefa.

Baixa temperatura

- Tradução;
- sumarização;
- classificação;
- respostas técnicas;
- geração de código.

Alta temperatura

- brainstorming;
- escrita criativa;
- geração de histórias;
- múltiplas ideias;
- diálogos mais diversos.

Em aplicações reais, temperatura é um hiperparâmetro importante para controlar o comportamento probabilístico do LLM.

Incerteza

Nem toda previsão confiante está correta.

Exemplo:

■ “A capital da Austrália é Sydney.”

O modelo pode responder isso com alta confiança.

Confiança não implica correção.

Hallucinations

Hallucinations são respostas incorretas produzidas com aparência convincente.

O modelo aprende padrões estatísticos, não necessariamente verdade factual.

Testes de hipótese

Frequentemente precisamos comparar modelos.

Exemplo:

- Modelo A $\rightarrow$ 88%
- Modelo B $\rightarrow$ 90%

Pergunta:

| essa diferença é estatisticamente significativa?

A inferência estatística ajuda a responder isso.

Bootstrap

Bootstrap gera várias amostras a partir dos próprios dados.

Permite:

- estimar variabilidade;
- construir intervalos;
- avaliar estabilidade.

Muito usado em ensemble learning.

Alta dimensionalidade

LLMs trabalham em espaços extremamente grandes.

Embeddings podem possuir milhares de dimensões.

Em alta dimensão:

- distâncias mudam de comportamento;
- visualização torna-se difícil.

Correlação não implica causalidade

LLMs aprendem principalmente associações estatísticas.

Exemplo:

- “jaleco” → “médico”

Isso representa associação, não causalidade.

Comentários Finais

“O Deep Learning moderno não substituiu a estatística; ele expandiu a inferência estatística para regimes de altíssima dimensionalidade e grande escala.”

Assim,

- Inferência estatística é um dos pilares da IA generativa;
- LLMs são modelos probabilísticos em alta dimensão;
- Probabilidade, estimação e generalização aparecem em praticamente toda IA moderna.