

“Não entre em Pânico!” (The Hitchhiker’s Guide to the Galaxy).

Espaços Métricos e Redes Siamesas

Paulo Lisboa de Almeida

Espaços Métricos

0 problema

Considere o problema de identificar se duas imagens pertencem à mesma pessoa.




= ???




0 problema

Ou ainda, o problema de identificar se duas assinaturas pertencem à mesma pessoa.



= ???



0 problema

O que esses problemas têm em comum?

0 problema

O que esses problemas têm em comum?

- Estamos comparando itens.
- Poucas amostras.
 - Exemplo: sua agência bancária ou cartório possui uma ou duas fotos ou assinaturas suas para comparar.
- É inviável treinar um modelo que reconheça todas as assinaturas ou fotos de pessoas possíveis.
 - Mesmo que tivéssemos amostras de todas pessoas do mundo, quando uma nova pessoa nascer, esse modelo se tornaria obsoleto.







Espaço Métrico

Desejamos criar um espaço onde vamos projetar amostras.

Amostras da mesma classe devem ficar próximas.

Amostras de classes diferentes devem ficar distantes.

Espaço Métrico



Espaço Métrico

A ideia por trás desse tipo de espaço é a mesma utilizada em diversos modelos.

Large Language Models.

Os *embeddings* de palavras que fazem parte do contexto atual ficam próximos no espaço.

Espaço Métrico

A ideia por trás desse tipo de espaço é a mesma utilizada em diversos modelos.

Large Language Models.

Os *embeddings* de palavras que fazem parte do contexto atual ficam próximos no espaço.

Self-supervised Learning.

Exemplo: O modelo aprende que patches de uma mesma imagem residem em posições próximas no espaço.

Espaço Métrico

A ideia por trás desse tipo de espaço é a mesma utilizada em diversos modelos.

Large Language Models.

Os *embeddings* de palavras que fazem parte do contexto atual ficam próximos no espaço.

Self-supervised Learning.

Exemplo: O modelo aprende que patches de uma mesma imagem residem em posições próximas no espaço.

Redes Siamesas.

Exemplo: A rede aprende a comparar itens. Itens da mesma classe residem em posições próximas no espaço.

Espaço Métrico

A ideia por trás desse tipo de espaço é a mesma utilizada em diversos modelos.

Large Language Models.

Os *embeddings* de palavras que fazem parte do contexto atual ficam próximos no espaço.

Self-supervised Learning.

Exemplo: O modelo aprende que patches de uma mesma imagem residem em posições próximas no espaço.

Redes Siamesas.


Exemplo: A rede aprende a comparar itens. Itens da mesma classe residem em posições próximas no espaço.

Vamos usar esse tipo de rede na aula para entender melhor esse tipo de espaço.

Redes Siamesas

Ideia

Redes de mesma estrutura para extrair a representação. **Embedding.**



Bromley, J., Guyon, I., LeCun, Y., Säckinger, E., & Shah, R. Signature verification using a "siamese" time delay neural network. Neurips. 1993.

Baldi, P., & Chauvin, Y. Neural networks for fingerprint recognition. Neural Computation. 1993.

Na Prática

Poderíamos ter “dois braços” idênticos da rede na memória, e computar as imagens em paralelo.

Rápido, mas ocupa o dobro da memória.

Na Prática

Poderíamos ter “dois braços” idênticos da rede na memória, e computar as imagens em paralelo.

Rápido, mas ocupa o dobro da memória.

Uma alternativa é manter somente um lado da rede, e mandar as imagens em sequência para ela.


Os dois braços da rede possuem a mesma estrutura e pesos.

Ideia Geral


```
def forward(self, input1, input2=None):  
    embedding1 = self.embedding_network(input1)  
  
    if input2 is None:  
        return embedding1  
  
    embedding2 = self.embedding_network(input2)  
    return torch.norm(embedding1 - embedding2, p=2, dim=1)
```

Experimento


O experimento a seguir é uma rede que usa a combinação das estruturas de rede dos seguintes artigos.



Schroff, F., Kalenichenko, D., & Philbin, J. FaceNet: A unified embedding for face recognition and clustering. CVPR. 2015.



BALNTAS, Vassileios et al. Learning local feature descriptors with triplets and shallow convolutional neural networks. In: Bmvc. 2016. p. 3.



Viotto, Heloísa Dias et al. How Far is Too Far? Defining the Distance Threshold for Verification Siamese Networks. SMC, 2026.


Triplet Loss

Triplet Loss.


Introduzido no Artigo da Facenet.

Cada amostra de treinamento é uma tripla (*triplet*) contendo uma âncora, uma imagem positiva, da mesma classe da âncora, e uma imagem negativa, de uma classe diferente.

âncora



positivo




negativo




Triplet Loss

O objetivo da rede é projetar as imagens em um espaço onde as âncoras e os exemplos positivos estão próximos, ao passo que as âncoras e os exemplos negativos estão distantes.

âncora



positivo



negativo




Triplet Loss


Desejamos que:

$$||x_i^a - x_i^p||_2^2 + \alpha < ||x_i^a - x_i^n||_2^2, \forall (x_i^a, x_i^p, x_i^n) \in \mathcal{T}$$

âncora



positivo



negativo



Onde:

x^a é a âncora.

x^p é a imagem positiva.

x^n é a imagem negativa.

$||\cdot||_2$ é a norma L2 (distância euclidiana).

$\mathcal{T}$ é o conjunto de todas as triplets, e tem tamanho N .


α é uma margem mínima entre pares positivos e negativos.

Triplet Loss


Logo, a função de Loss fica:

$$L = \sum_i^N ||x_i^a - x_i^p||_2^2 - ||x_i^a - x_i^n||_2^2 + \alpha$$

âncora



positivo



negativo



Onde:

x^a é a âncora.

x^p é a imagem positiva.

x^n é a imagem negativa.

$||\cdot||_2$ é a norma L2 (distância euclidiana).

$\mathcal{T}$ é o conjunto de todas triplets, e tem tamanho N .


α é uma margem mínima entre pares positivos e negativos.

Triplet Loss


Logo, a função de Loss fica:

$$L = \sum_i^N ||x_i^a - x_i^p||_2^2 - ||x_i^a - x_i^n||_2^2 + \alpha$$

âncora



positivo



negativo



Detalhe: no exemplo disponibilizado no Moodle usamos a função de loss de Balntas et al., que é um pouco diferente, mas segue a mesma ideia.

Onde:

x^a é a âncora.

x^p é a imagem positiva.

x^n é a imagem negativa.

$||\cdot||_2$ é a norma L2 (distância euclidiana).

$\mathcal{T}$ é o conjunto de todas triplets, e tem tamanho N .

α é uma margem mínima entre pares positivos e negativos.

Facenet

Existem ainda outros detalhes no artigo, como garantir que os dados residem em uma hiperesfera de raio 1, e que as triplets sejam “difíceis” para melhorar a convergência e evitar o colapso da rede na origem.

Veja os detalhes nos artigos.



Faça você mesmo

Execute e entenda o exemplo disponibilizado.

A blue parallelogram graphic with a black border and a slight 3D effect, centered on a black background. The text "Limiar de Decisão" is written in white inside the parallelogram.

Limiar de Decisão

Limiar de Decisão

Note que o problema depende de um limiar de decisão.

Dado um par de imagens, calcular a distância desse par.

Se a distância for maior que o limiar, o sistema diz que as amostras são de classes diferentes. Caso contrário, da mesma classe.

Limiar de Decisão

Definir o limiar não é trivial.

Em especial, a distância euclidiana é problemática em espaços com muitas dimensões.

Ideias clássicas.

- Testar múltiplos limiares de decisão em um dataset de validação.
 - Algo similar a isso está feito no código disponibilizado.
- Calcular o Equal Error Rate no Espaço ROC, usando validação.
 - **Ideia melhor.**
 - Garantimos que testamos todos limiares, e que não ficamos tendenciosos caso o problema seja desbalanceado.

How Far is Too Far?



Se calcularmos a distância de diversos pares, esperamos ter uma distribuição bimodal.

Uma moda para pares da mesma classe (e.g., mesma pessoa).

Uma moda para pares diferentes (e.g., pessoas diferentes).

Podemos utilizar o vale entre essas distribuições como limiar de decisão.

Não precisamos de dados rotulados para isso.



Limiar de Decisão

Podemos modelar um problema de classificação com esse tipo de rede.

Como?

Limiar de Decisão

Podemos modelar um problema de classificação com esse tipo de rede.

Exemplo:

Ao chegar um dado que precisa ser classificador, calcular o vizinho mais próximo do dado (os dados vizinhos são dados rotulados de treinamento).

Assumimos que o dado a ser classificado possui a mesma classe do vizinho mais próximo.

Aqui, mais uma vez, podemos usar a ideia de limiar.

Se a distância for maior que o limiar, podemos dizer que a classificação não foi possível pois não há nenhuma amostra similar disponível.

Estado da arte

Essas ideias podem ser estendidas para diversos problemas e métodos do estado da arte. Exemplos:

One-shot learning.

Zero-shot learning.

Exercícios

1. Teste a rede usando todos os dígitos.
2. Teste a rede dando mais épocas de treino. O que acontece com os clusters conforme as épocas avançam?
3. Teste usando embeddings maiores. O que acontece? A acurácia sobe?
 - a. Aqui você vai precisar desabilitar a visualização 2D dos dados.
4. Modifique o problema para criar um sistema de busca de números.
 - a. Dada a imagem de um número desconhecido, verificar qual é o número.
 - b. Use uma IA generativa de sua preferência para te ajudar a programar o problema.
5. Desafio: Leia o artigo *How far is Too far?*, e modifique o cálculo de limiar de decisão para utilizar o método proposto no artigo.
 - a. Use uma IA generativa para te ajudar.